Flow Matching. Quick Tour

Постановка задачи генерации

Пусть:

- $p_0(x)$ — простое распределение (например, $\mathcal{N}(0, I)$),
- $p_1(x)$ — целевое распределение данных.

Задача: построить непрерывное отображение

$$\psi_1 : \mathbb{R}^d \to \mathbb{R}^d,$$

такое что

$$[\psi_1]_{\#} p_0 = p_1.$$

Т.е. $X_1 = \psi(X_0) \sim p_1 \iff X_0 \sim p_0$
Вместо прямого построения ψ_1 рассматриваем поток

$$\frac{d}{dt}\psi_t(x) = v_t(\psi_t(x)), \quad t \in [0, 1].$$

Поток и уравнение непрерывности

Если ψ_t удовлетворяет

$$\frac{d}{dt}\psi_t(x) = v_t(\psi_t(x)),$$

то плотность p_t удовлетворяет уравнению непрерывности:

$$\partial_t p_t(x) + \nabla \cdot \big(p_t(x) v_t(x)\big) = 0.$$

Идея:

- если мы найдём правильное v_t,
- то интегрирование ОДУ перенесёт p_0 в p_1.

Flow Matching: ключевая идея

Вместо обучения через log-likelihood (CNF), Flow Matching предлагает:

1. Задать интерполирующее распределение p_t между p_0 и p_1.
2. Вычислить соответствующее «истинное» поле скоростей $u_t(x)$.
3. Обучать модель v_θ по регрессии:

$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}_{t\sim U[0,1],\, x\sim p_t} \| v_\theta(t,x) - u_t(x) \|^2.$$

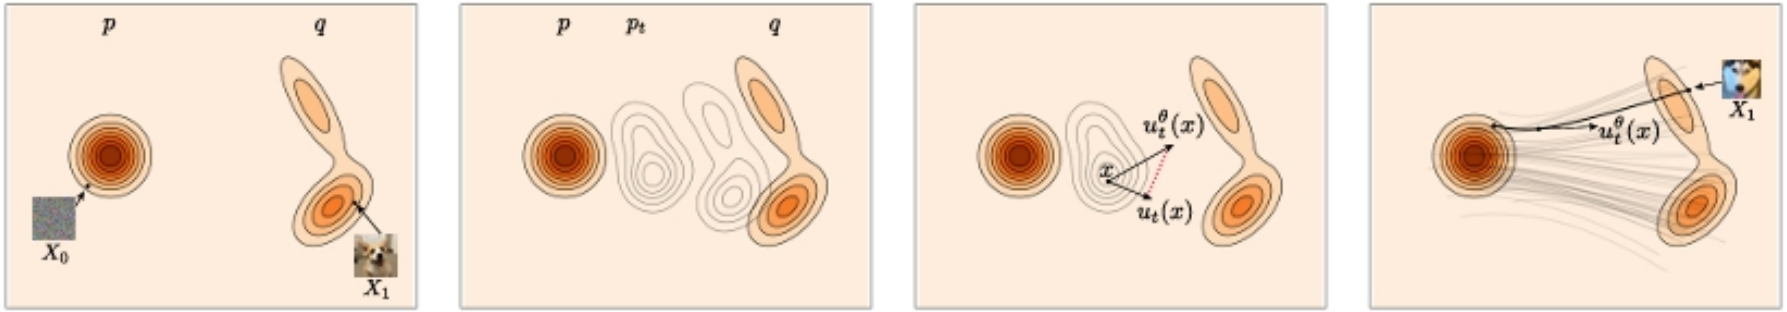

(a) Data. **(b)** Path design. **(c)** Training. **(d)** Sampling.

Figure 2 *The Flow Matching blueprint.* (a) The goal is to find a flow mapping samples X_0 from a known source or noise distribution q into samples X_1 from an unknown target or data distribution q. (b) To do so, design a time-continuous probability path $(p_t)_{0 \leq t \leq 1}$ interpolating between $p := p_0$ and $q := p_1$. (c) During training, use regression to estimate the velocity field u_t known to generate p_t. (d) To draw a novel target sample $X_1 \sim q$, integrate the estimated velocity field $u_t^\theta(X_t)$ from $t = 0$ to $t = 1$, where $X_0 \sim p$ is a novel source sample.

Пример: линейная интерполяция

Простейший случай:

$$X_t = (1 - t)X_0 + tX_1.$$

Тогда условное поле скоростей:

$$u_t(x|x_0, x_1) = x_1 - x_0.$$

Проблема:

- чтобы вычислить истинное $u_t(x)$, нужно усреднять по условному распределению.

Условная формулировка

Вместо работы с маргинальным $u_t(x)$ вводится

$$u_t(x|z),$$

где z — латентная переменная (например, пара (x_0, x_1)).
Тогда условный лосс:

$$\mathcal{L}_{\text{cond}} = \mathbb{E}_{t,z,x_t} \| v_\theta(t, x_t) - u_t(x_t|z) \|^2.$$

Это легко сэмплировать:

- берём z,
- генерируем x_t,
- знаем $u_t(x_t|z)$ аналитически.

Тогда истинное поле выражается как

$$u_t(x) = \mathbb{E}\big[u_t(x|z) \mid X_t = x\big].$$

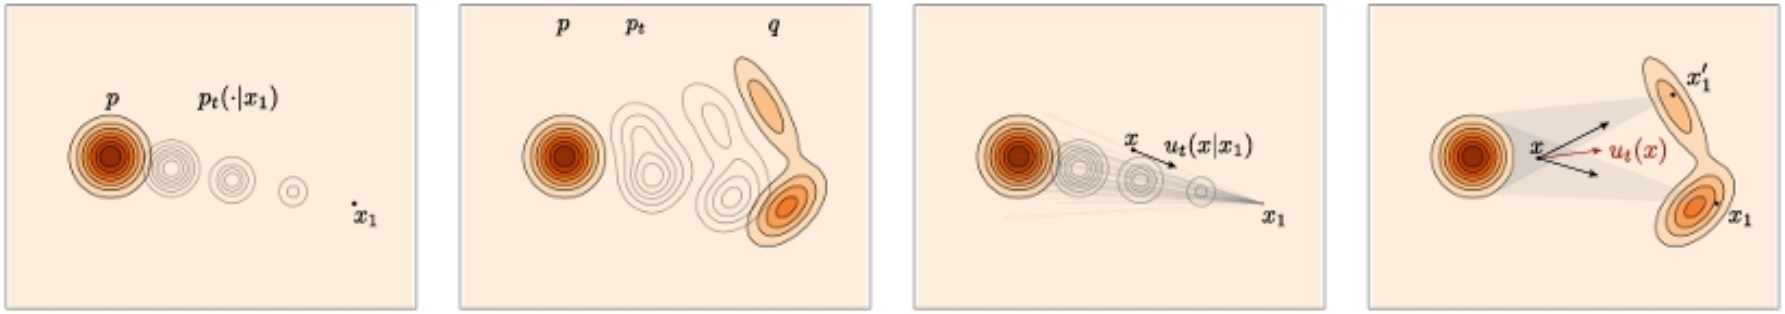

(a) Conditional probability path $p_t(x|x_1)$.

(b) (Marginal) Probability path $p_t(x)$.

(c) Conditional velocity field $u_t(x|x_1)$.

(d) (Marginal) Velocity field $u_t(x)$.

Figure 3 *Path design in Flow Matching.* Given a fixed target sample $X = x_1$, its conditional velocity field $u_t(x|x_1)$ generates the conditional probability path $p_t(x|x_1)$. The (marginal) velocity field $u_t(x)$ results from the aggregation of all conditional velocity fields—and similarly for the probability path $p_t(x)$.

Теорема о совпадении лоссов

Теорема.
Минимизатор условного лосса совпадает с минимизатором маргинального лосса:

$$\arg\min_v \mathcal{L}_{\text{cond}} = \arg\min_v \mathcal{L}_{\text{marg}},$$

где

$$\mathcal{L}_{\text{marg}} = \mathbb{E}_{t,x\sim p_t}\|v(t,x) - u_t(x)\|^2.$$

Главная идея доказательства

Рассмотрим разложение:

$$u_t(x|z) = u_t(x) + \varepsilon,$$

где

$$\mathbb{E}[\varepsilon \mid x] = 0.$$

Тогда:

$$\|v - u_t(x|z)\|^2 = \|v - u_t(x)\|^2 + \|\varepsilon\|^2 + 2\langle v - u_t(x), \varepsilon\rangle.$$

После взятия условного ожидания:

$$\mathbb{E}[\langle v - u_t(x), \varepsilon\rangle \mid x] = 0.$$

Следствие

Получаем:

$$\mathcal{L}_{\text{cond}} = \mathcal{L}_{\text{marg}} + \text{константа}.$$

Константа не зависит от v.

Следовательно:

минимизатор один и тот же.

Интерпретация

Это означает:

- мы можем обучать модель, имея только условное поле
- но в результате выучим истинное маргинальное поле

Flow	Velocity field	Probability path	Boundary conds.	Loss

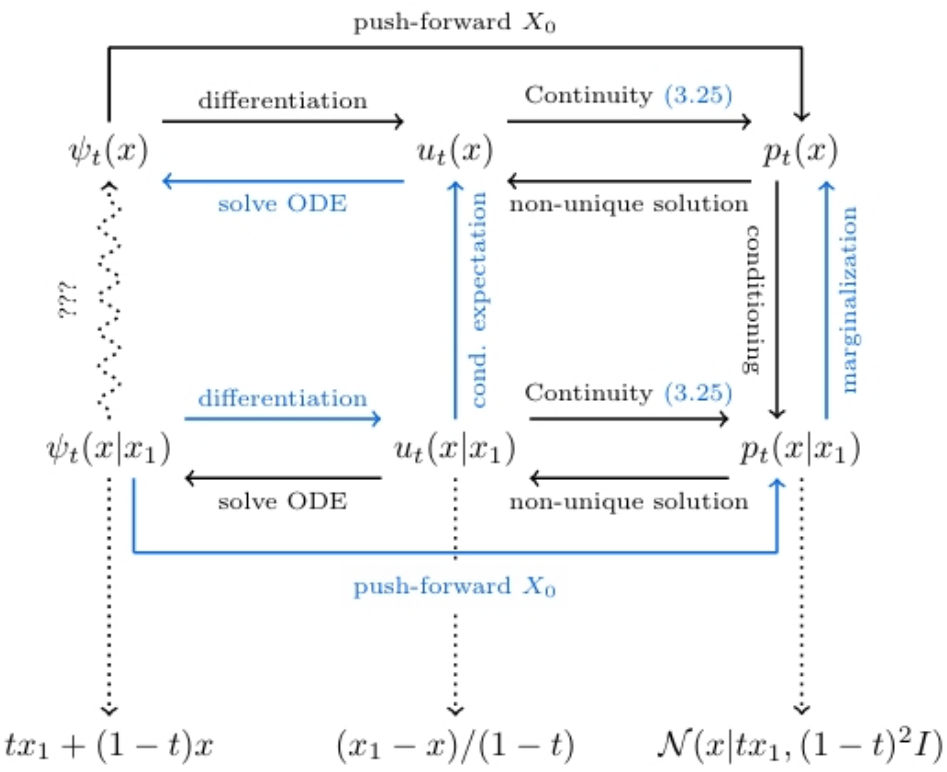

$p_0 = p$ $p_1 = q$	**Flow Matching (FM)** (4.22) $D\left(u_t(X_t), u_t^\theta(X_t)\right)$
$p_0 = p$ $p_1 = \delta_{x_1}$	**Conditional FM (CFM)** (4.23) $D\left(u_t(X_t\|X_1), u_t^\theta(X_t)\right)$
$p_0 = \mathcal{N}(0, I)$ $p_1 = \delta_{x_1}$	**OT, Gauss CFM** (2.9) $\|u_t^\theta(X_t) - (X_1 - X_0)\|^2$

Итог

Flow Matching:

- избегает log-likelihood
- легко обучается
- позволяет обучать настоящий поток через условные конструкции.